

SVEUČILIŠTE U ZAGREBU
FAKULTET ELEKTROTEHNIKE I RAČUNARSTVA

DIPLOMSKI RAD br. 1469

**MODEL KOHERENTNOG OPTIČKOG
SUSTAVA KORIŠTENOG U LASERSKOJ
MIKROSKOPIJI**

Josip Vukušić

Zagreb, lipanj 2017.

SVEUČILIŠTE U ZAGREBU
FAKULTET ELEKTROTEHNIKE I RAČUNARSTVA

DIPLOMSKI RAD br. 1469

**MODEL KOHERENTNOG OPTIČKOG
SUSTAVA KORIŠTENOG U LASERSKOJ
MIKROSKOPIJI**

Josip Vukušić

Zagreb, lipanj 2017.

Sadržaj

Uvod	1
1. Model optičkog sustava	2
1.1. Huygens-Fresnelov princip	2
1.2. Fresnelova aproksimacija	5
1.3. Implementacija Fresnelovog difrakcijskog integrala	6
2. Modeliranje objekta	8
2.1. Tanka leća	8
2.1.1. Funkcija debljine leće	9
2.1.2. Gaussova aproksimacija	10
3. Rekonstrukcija objekta	12
3.1. Metodologija	12
4. Sažimajuće očitavanje	15
4.1. Motivacija	15
4.2. Osnovna svojstva	16
4.3. Dizajn mjerne matrice	17
4.4. Rekonstrukcijski algoritmi	18
4.4.1. L2 norma	18
4.4.2. L0 norma	19
4.4.3. L1 norma	20
5. Implementacija i rezultati	21
5.1. Eksperimenti s jednom pukotinom	21
5.2. Rekonstrukcija objekta	25
5.3. Sažimajuće očitavanje	28

6. Diskusija	31
Zaključak	32
Literatura	33
Sažetak.....	34
Summary.....	35
Skraćenice.....	36
Privitak	37

Uvod

Kako bi mogli izvoditi sintetičke eksperimente te olakšali testiranje nadogradnji laserskog mikroskopa u ovom radu razvili smo matematički i simulacijski model koherentnog optičkog sustava.

Ovaj rad možemo podijeliti na tri dijela. Prvi dio je simulacija model optičkog sustava koji se sastoji od izvora koherentnog svjetla zadane valne duljine, prozirnog objekta s različitom brzinom prostiranja svjetlosti od vakuuma te zaslona na kojemu se projicira slika objekta. Ovakav model optičkog sustava je razvijen na temelju Huygens-Fresnelovog principa superpozicije točkastih izvora te je objekt modeliran svojom faznom karakteristikom. Drugi dio rada je rekonstrukcija objekta pomoću optičke mreže te faznih pomaka koji nastaju prolaskom svjetla kroz predmet. Treći dio je rekonstrukcija slike visoke rezolucije iz malog broja mjerenja sažimajućim očitavanjem. U prvom dijelu rada bit će opisana teorijska osnova koja je potrebna za izgradnju jednog takvog sustava te u drugom dijelu će biti opisana implementacija sustava.

1. Model optičkog sustava

Optički sustav koji modeliramo u ovom radu vrlo je jednostavan: laserski izvor koherentnog svjetla prolazi kroz pukotinu, obasjava objekt te ta svjetlost dolazi do projekcijske ravnine na kojoj se nalaze senzori. Problem modeliranja ovakvog sustava možemo razbiti na tri potproblema. Prvi je modeliranje difrakcije svjetlosti na pukotini, zatim propagacija svjetlosti kroz vakuum i treći je fazna modulacija svjetlosti prolaskom kroz objekt. U ovom poglavlju bavit ćemo se s prva dva potproblema.

Najčešći načini za modeliranje valova u fizikalnoj optici su aproksimativni modeli jer točni modeli koji se temelje na Maxwellovim jednažbama su previše složeni, a aproksimativni modeli daju jako dobre rezultate. Mi ćemo za modeliranje našeg optičkog sustava koristiti Fresnelovu aproksimaciju. Prvo ćemo opisati koncept intenziteta svjetlosti, a zatim Huygens-Fresnelov princip iz kojeg je kasnije izvedena Fresnelova aproksimacija.

1.1. Huygens-Fresnelov princip

Uzmimo izvorišnu točku na mjestu P_0 koja vibrira na frekvenciji f . Poremećaj koji uzrokuje vibracija možemo opisati kompleksnom varijablom U_0 koju nazivamo kompleksna amplituda. Poremećaj uzrokuje sferni val s valnom duljinom λ , valnog broja $k = 2\pi/\lambda$. Kompleksna amplituda primarnog vala u točki Q koja se nalazi na udaljenosti r_0 od točke P_0 dana je izrazom 1.1.

$$U(r_0) = \frac{U_0 e^{ikr_0}}{r_0} \quad (1.1)$$


Koristeći Huygensov teoriju i princip superpozicije valova, kompleksna amplituda na udaljenoj točki P se dobiva zbrajanjem doprinosa svake točke na sferi radijusa r_0 . Kako bi dobio slaganje s eksperimentalnim rezultatima Fresnel je otkrio da individualni doprinosi sekundarnih valova moraju biti pomnoženi konstantom $-i/\lambda$ te se mora zbrojiti nagibni faktor $K(\chi)$. Množenje s konstantom znači da sekundarni val oscilira za $\frac{\pi}{2}$ izvan faze primarnog vala i da je magnituda sekundarnog vala u omjeru $1:\lambda$ primarnog vala. Također se pretpostavlja da $K(\chi)$ ima minimalnu vrijednost kad je $\chi = 0$ i da je jednako 0 kad je $\chi =$

$\frac{\pi}{2}$. Kompleksna amplituda točke P je dana izrazom (1.2) gdje S označava sferu, a s je udaljenost između Q i P.

$$U(P) = -\frac{i}{\lambda} U(r_0) \int_S \frac{e^{iks}}{s} K(\chi) dS \quad (1.2)$$

Kirchhoff je predložio izraz 1.3 gdje χ ima maksimalnu vrijednost u $\chi = 0$ kao u Huygens-Fresnelovom principu međutim χ nije jednak 0 za $\chi = \frac{\pi}{2}$.

$$K(\chi) = \frac{1}{2}(1 + \cos\chi) \quad (1.3)$$



Slika 1.1 Geometrijski prikaz jednodimenzionalnog Huygens-Fresnelovog principa

Sada ćemo iskazati princip u slučaju pravokutnih koordinata za dvodimenzionalni slučaj. Kako je prikazano na slici 1.2 difrakcijska pukotina je postavljena u (ξ, η) ravnini te je osvijetljena u pozitivnom smjeru z osi. Računamo valnu frontu u točki (x, y) ravnine koja je paralelna s (ξ, η) ravninom na udaljenosti z. z os probada obje ravnine na njihovim ishodištima. Tada Huygens-Fresnelov princip je dan izrazom 1.4 gdje je θ kut između normale $\vec{n}$ i vektora $\vec{r}_{01}$ koji je usmjeren od P_0 prema P_1 .

$$U(P_0) = \frac{1}{j\lambda} \iint_{\Sigma} U(P_1) \frac{e^{jkr_{01}}}{r_{01}} \cos\theta dS \quad (1.4)$$

Tada je $\cos\theta$ dan izrazom 1.5.

$$\cos\theta = \frac{z}{r_{01}} \quad (1.5)$$


Uvrštavanjem izraza 1.5 u izraz 1.4 izraz 1.5.

$$U(P_0) = \frac{z}{j\lambda} \iint_{\Sigma} U(P_1) \frac{e^{jkr_{01}}}{r_{01}^2} d\xi d\eta \quad (1.6)$$

Udaljenost r_{01} dana je izrazom (1.7).

$$r_{01} = \sqrt{z^2 + (x - \xi)^2 + (y - \eta)^2} \quad (1.7)$$

Kako bi došli do ovog izraza koristili smo samo dvije aproksimacije. Prva aproksimacija je naslijeđena iz skalarne teorije. Druga aproksimacija je pretpostavka da projekcijska ravnina je udaljena puno više od iznosa valne duljine svjetlosti od pukotine $r_{01} \gg \lambda$. (Goodman, 1996.)



Slika 1.2 Geometrijski prikaz dvodimenzionalnog Huygens-Fresnelovog principa. Slika preuzeta iz (Goodman, 1996.)

1.2. Fresnelova aproksimacija

Kako bi dobili jednostavniji i upotrebljiviji izraz uvodimo aproksimaciju za izračun udaljenosti r_{01} između točaka P_1 i P_0 . Kako bi aproksimirali vrijednost kvadratnog korijena koristimo se binomnom rastavom kvadratnog korijena. Neka je b broj manji od nule te uzmimo izraz $\sqrt{1+b}$ tada je binomni rastav ovog izraza dan s

$$\sqrt{1+b} = 1 + \frac{1}{2}b + \frac{1}{8}b^2 + \dots \quad (1.8)$$

gdje je broj članova koji je potreban za određenu preciznost ovisi o veličini broja b .

Kako bi primijenili ovako definiranu aproksimaciju na naš problem izlučujemo z izvan korijena te dobivamo izraz 1.9.

$$r_{01} = \sqrt{1 + \left(\frac{x-\xi}{z}\right)^2 + \left(\frac{x-\eta}{z}\right)^2} \quad (1.9)$$

Koristeći izraz 1.8 kako bi izrazili udaljenost r_{01} dobivamo izraz 1.10

$$r_{01} \approx z \left[1 + \frac{1}{2} \left(\frac{x-\xi}{z}\right)^2 + \frac{1}{2} \left(\frac{x-\eta}{z}\right)^2 \right] \quad (1.10)$$

gdje smo za b uzeli drugi i treći član ispod korijena u izrazu 1.9 te razvili dva člana izraza. Ovisno na mjestu na kojem se pojavljuje izraz za udaljenost možemo odrediti koliko članova izraza 1.19 ćemo koristiti u aproksimaciji izraza 1.6. Za element r_{01}^2 koji se pojavljuje u nazivniku greška koja nastaje odbacivanjem svih članova osim z je prihvatljivo mala. Za r_{01} koji se pojavljuje u eksponentu moramo biti puno pažljiviji jer pogreške na tom mjestu su puno kritičnije. Vidimo da se udaljenost množi s k koji u vidljivom spektru je reda veličine 10^7 , zatim trebamo primijetiti da promjena faza mijenja za male frakcije radijana može značajno promijeniti vrijednost eksponencijale. Iz tih razloga zadržavamo sve članove aproksimacije u eksponentu. Nakon ovih aproksimacija dobivamo izraz za polje u točki (x, y) .

$$U(x, y) = \frac{e^{jkz}}{j\lambda z} \iint_{-\infty}^{\infty} U(\xi, \eta) \exp \left\{ j \frac{k}{2z} [(x - \xi)^2 + (y - \eta)^2] \right\} d\xi d\eta \quad (1.11)$$

Izraz 1.11 možemo izraziti u obliku konvolucije:

$$U(x, y) = \iint_{-\infty}^{\infty} U(\xi, \eta) h(x - \xi, y - \eta) d\xi d\eta \quad (1.12)$$

gdje je konvolucijska jezgra (engl. *kernel*):

$$h(x, y) = \frac{e^{jkz}}{j\lambda z} \exp \left\{ j \frac{k}{2z} [x^2 + y^2] \right\}. \quad (1.13)$$

Možemo zapisati još jedan oblik rezultata 1.10 ako proširimo kvadrate binoma u eksponentu:

$$U(x, y) = \frac{e^{jkz}}{j\lambda z} e^{j \frac{k}{2z} (x^2 + y^2)} \iint_{-\infty}^{\infty} \left\{ U(\xi, \eta) e^{j \frac{k}{2z} (\xi^2 + \eta^2)} \right\} e^{-j \frac{2\pi}{\lambda z} (x\xi + y\eta)} d\xi d\eta. \quad (1.14)$$

U dobivenom izrazu prepoznamo Fourierovu transformaciju produkta kompleksnog polja neposredno pukotini te kvadratnoj fazi eksponencijale.

Za oba oblika rezultata 1.11 i 1.14 koristimo termin Fresnelov difrakcijski integral. (Goodman, 1996.)

1.3. Implementacija Fresnelovog difrakcijskog integrala

Kako bi problem mogli riješiti numerički potrebno ga je zapisati u diskretnoj formi. Prva stvar koju moramo učiniti je očitati signal određenom frekvencijom, diskretizacija. Ovaj problem nećemo detaljnije opisivati. Jednom kada imamo diskretni početni signal, početna jakost svjetlosnog polja U_0 , primjenjujemo izraz 1.11 za izračun jakosti svjetlosnog polja u nekoj točki. Integrale zamjenjujemo sumama čije su granice određene veličinom pukotine. Uzmemo li pravokutnu pukotinu čija je stranica veličine n (n nije veličina izražena u metrima nego duljina polja u memoriji računala, ova vrijednost ovisi o frekvenciji očitavanja signala) tada za izračun svjetlosnog polje u točki dobivamo složenost $O(n^2)$. Želimo li dobiti dvodimenzionalnu sliku na projekcijskoj ravnini moramo računati vrijednost polja za svaku točku slike. Ako uzmemo da je željena slika pravokutna sa stranicom veličine m dobivamo ukupnu složenost implementacije Fresnelove aproksimacije $O(n^2 * m^2)$. Tipične vrijednosti za m i n su 8000 te je složenost algoritma prevelika za izračun na jednoj jezgri računala.

Ovaj problem se trivijalno može riješiti paralelnim programiranjem na više jezgri procesora ili grozdu računala, svaka točka rezultata se može računati neovisno o ostalim točkama. Međutim postoji još jedan način izračuna Fresnelove aproksimacije koja omogućava brzo izvršavanje na jednom računalu.

Pogledamo li izraz 1.12 vidimo da je to konvolucija dviju funkcija te možemo iskoristiti teorem o Fourierovoj transformaciji konvolucije. Neka su f i g kvadratno integrabilne funkcije tada je

$$\mathcal{F}[f * g] = \sqrt{2\pi} \hat{f} \cdot \hat{g} \quad (1.15)$$

$$\mathcal{F}^{-1}[\hat{f} \cdot \hat{g}] = \frac{1}{\sqrt{2\pi}} f * g \quad (1.16)$$

Ovaj trik možemo iskoristiti te našu konvoluciju iz izraza 1.12 izračunati u Fourierovoj domeni te ćemo tako znatno ubrzati izračun. Za izračun Fourierove transformacije koristimo algoritam brze Fourierove transformacije (*engl.* Fast Fourier transform FFT) koji ima teorijsku složenost $O(n \log n)$. Množenje provodimo nad svakim članom strukture u koju je pohranjena početna odnosno krajnja vrijednost jakosti polja te je složenost tog izračuna $O(n^2)$ te tako dobivamo i ukupnu složenost Fresnelove aproksimacije $O(n^2)$. Na ovaj način smo smanjili složenost za dva reda veličine te je brzina izvođenja na jednoj jezgri računala prihvatljiva za normalan rad.

2. Modeliranje objekta

Promatrani objekt u modelu optičkog sustava kojeg razvijamo je proziran te svjetlost u njemu prostire različitom brzinom od brzine svjetlosti u vakuumu. Kako bi izračunali faznu transformaciju koja nastaje zbog različite brzine prolaska svjetlosti kroz promatrani objekt poslužit ćemo se modelom tanke leće. Kako je naš optički sustav zapravo model mikroskopa promatrani objekti su vrlo mali te je zbog toga tanka leća vrlo dobar model s kojim možemo opisati objekt.

2.1. Tanka leća

Leće se izrađuju od optički gustih materijala, najčešće je to staklo čiji je indeks loma 1.5 te je brzina svjetlosti u njemu manja od brzine svjetlosti u vakuumu. Za leću kažemo da je tanka ako zraka koja ulazi u točki (x, y) na jednoj strani postoji na približno istim koordinatama na drugoj strani leće odnosno ako postoji neznatna translacija zrake unutar leće. Drugim riječima tanka leća samo usporava ulazeće zrake za iznos proporcionalan debljini leće u svakoj točki. (Goodman, 1996.)

Neka je maksimalna debljina leće Δ_0 te neka je debljina leće u točki (x, y) jednaka $\Delta(x, y)$ kako je prikazano na slici 2.1. Fazni pomak svjetlosti koja ulazi u točki (x, y) u leću možemo opisati jednadžbom 2.1 gdje je n indeks loma leće, $kn\Delta(k, y)$ je fazni pomak uzrokovan lećom, a $k[\Delta_0 - \Delta(x, y)]$ fazni pomak uzrokovan praznim prostorom između dvije ravnine.

$$\Phi(x, y) = kn\Delta(k, y) + k[\Delta_0 - \Delta(x, y)] \quad (2.1)$$


Također leću možemo predstaviti kao umnožak faznih transformacija (izraz 2.1).

$$t_l(x, y) = \exp[jk\Delta_0] \exp[jk(n - 1)\Delta(x, y)] \quad (2.2)$$

Tada je izraz kompleksnog polja $U'_l(x, y)$ na ravnini neposredno iza leće povezan s kompleksnim poljem $U_l(x, y)$ koje se nalazi neposredni ispred leće izrazom 2.3.

$$U'_l(x, y) = t_l(x, y)U_l(x, y) \quad (2.3)$$


U sljedećem potpoglavlju definirati ćemo funkciju debljine $\Delta(x, y)$ leće kako bi mogli bolje razumjeti i ostale utjecaje leće.



Slika 2.1 Tanka leća. (a) Prednja strana leće. (b) Stražnja strana leće. Slika preuzeta iz (Goodman, 1996.).

2.1.1. Funkcija debljine leće

Prva stvar koju moramo definirati je predznak polumjera sfernog dioptra koji omeđuju leću. Dogovorno uzimamo da konveksne površine kroz koje zraka svjetlosti koja putuje s lijeva na desno prolazi imaju pozitivne polumjere dok konkavne površine imaju negativne polumjere. Na slici 2.1 (b) radijus lijevoga dioptra je pozitivan broj R_1 dok je radijus desnoga dioptra negativan broj R_2 .



Slika 2.2 Rastav leće na tri komponente. (a) Geometrija za Δ_1 . (b) Geometrija za Δ_2 . (c) Geometrija za Δ_3 . Slika preuzeta iz (Goodman, 1996.).

Kako bi pronašli funkciju debljine leće $\Delta(x, y)$ podijelit ćemo leću na tri dijela kako je prikazano slikom 2.2 te ćemo izraz za gustoću napisati kao zbroj ta tri komponente leće.

$$\Delta(x, y) = \Delta_1(x, y) + \Delta_2(x, y) + \Delta_3(x, y) \quad (2.4)$$

Koristeći sliku 2.2 možemo zapisati izraze za sve tri komponente leće. Tako za prvi dio leće dobivamo izraz 2.2.

$$\Delta_1(x, y) = \Delta_{01} - \left(R_1 - \sqrt{R_1^2 - x^2 - y^2} \right) = \Delta_{01} - R_1 \left(1 - \sqrt{1 - \frac{x^2 + y^2}{R_1^2}} \right) \quad (2.5)$$

Druga komponenta funkcije debljine leće je konstanta Δ_{01} . Treća komponenta je dana izrazom 2.3.

$$\Delta_3(x, y) = \Delta_{03} - \left(R_2 - \sqrt{R_2^2 - x^2 - y^2} \right) = \Delta_{03} - R_2 \left(1 - \sqrt{1 - \frac{x^2 + y^2}{R_2^2}} \right) \quad (2.6)$$

Kombinirajući ova tri izraza za debljine pojedinih komponenti leće dobivamo izraz za cijele debljinu leće:

$$\Delta(x, y) = \Delta_0 + R_1 \left(1 - \sqrt{1 - \frac{x^2 + y^2}{R_1^2}} \right) + R_2 \left(1 - \sqrt{1 - \frac{x^2 + y^2}{R_2^2}} \right) \quad (2.7)$$

gdje je $\Delta_0 = \Delta_{01} + \Delta_{02} + \Delta_{03}$.

2.1.2. Gaussova aproksimacija

Ovu aproksimaciju u literaturi nalazimo i pod imenom paraksijalna aproksimacija. Ova aproksimacija se ograničava na zrake svjetlosti, valne fronte, koje pod malim kutom u odnosu na njihove optičke osi dolaze do leće. Tako razmatramo samo male vrijednosti x i y kako bi mogli napraviti aproksimacije dane izrazom 2.4.

$$\left(1 - \sqrt{1 - \frac{x^2 + y^2}{R_1^2}}\right) \approx 1 - \frac{x^2 + y^2}{2R_1^2}, \quad \left(1 - \sqrt{1 - \frac{x^2 + y^2}{R_2^2}}\right) \approx 1 - \frac{x^2 + y^2}{2R_2^2} \quad (2.8)$$

S ovim aproksimacijama rezultat fazne transformacije bit će točan na ograničenom prostoru leće, ali ova ograničenja nisu restriktivnija od uobičajenih aproksimacija u geometrijskoj optici. Možemo primijetiti da izrazi 2.3 odgovaraju aproksimaciji sfernih ploha leće paraboličnim plohama. Konačno uz upotrebu navedenih aproksimacija dobivamo izraz za funkciju debljine leće.


$$\Delta(x, y) = \Delta_0 + \frac{x^2 + y^2}{2} \left(\frac{1}{R_1} - \frac{1}{R_2} \right) \quad (2.9)$$

3. Rekonstrukcija objekta

Do sada smo govorili o modelu optičkog sustava odnosno o modeliranju monokromatskog svjetla koje putuje kroz vakuum te konačno dolazi projekcijske ravnine na kojoj možemo izračunati intenzitet svjetla. Zatim smo definirali model objekta kojeg smo modelirali pomoću tanke leće i zbog tog objekta svjetlost dobiva pomak u fazi te na projekcijskoj ravnini na mjestima koja su pod utjecajem objekta vidimo pomake u fazi. No ono što u konačnici želimo dobiti kao rezultat ovog optičkog sustava je rekonstrukcija objekta odnosno želimo vidjeti sliku našeg objekta kojega smo prethodno definirani. Za rekonstrukciju objekta poslužiti ćemo se metodom faznog kontrasta korištenjem optičke rešetke. Ideja ove metode je analiza deformacije koje nastaju zbog objekta u odnosu na referentne uzorke koje nastaju zbog optičke rešetke. U ovom poglavlju ćemo opisati ovu metodu.

3.1. Metodologija

Eksperiment je postavljen kao na slici 3.1, nakon izvora svjetlost nalazi se optička rešetka iza koje je odmah postavljen predmet te imamo senzor u projekcijska ravnina. Na početku ne stavljamo predmet te mjerimo referentni uzorak koji nastaje zbog optičke rešetke. Nakon toga postavljamo predmet zbog kojeg nastaju pomaci u fazi te na senzoru dobivamo izobličenu sliku referentnog uzorka. Fazni pomak φ u svakoj točki projekcijske ravnine možemo izračunati pomoću dijagonalnog pomaka referentnog uzorka S kojeg razlažemo na horizontalni pomak S_x i vertikalni pomak S_y



Slika 3.1 Prikaz eksperimenta za rekonstrukciju objekta. Slika preuzeta iz (Morgan et al. 2001.).

Iz slike 3.1 možemo napisati izraze

$$\tan\theta_x = \frac{S_x}{z}, \tan\theta_y = \frac{S_y}{z} \quad (3.1)$$

gdje su θ_x i θ_y promjena kuta zrake u smjeru x i y osi koje nastaju zbog predmeta te rezultiraju dijagonalnim pomakom S referentnog uzorka.

Uspoređujući slike dobivene korištenjem samo rešetke te slike dobivene korištenjem rešetke i objekta računamo pomake za svaki piksel. Rezolucija dobivene slike je određena veličinom optičke rešetke tako da je jedan piksel zapravo jedno okno u rešetci. Pomake računamo pomoću težinskog centra mase (engl. *weighted center of mass*) gdje za mjeru uzimamo intenzitet svjetla. Računajući pomake S_x i S_y za svaki piksel (x, y) dobivamo dvije slike faznih pomaka po dvije osi. Koristeći izraz 3.1 možemo te pomake konvertirati u kuteve θ_x i θ_y . Za svjetlost valne dužine λ faza dubina objekta $\varphi(x, y)$ će skrenuti upadne zrake za kuteve θ_x i θ_y prema izrazu 3.2.

$$\theta_x = \frac{1}{\lambda} \frac{\partial \varphi}{\partial x}, \quad \theta_y = \frac{1}{\lambda} \frac{\partial \varphi}{\partial y} \quad (3.2)$$

Kombinirajući izraze 3.1 i 3.2 te ako pretpostavimo da je objekt izrađen od istog materijala tako da je $\varphi = -k\delta T$ gdje je δ indeks refleksije čija je vrijednost manja od 1 i T je projicirana debljina, gradijent funkcije debljine je dan izrazom 3.3 za oba smjera.

$$\frac{\partial T}{\partial x} = \frac{1}{\delta} \tan^{-1} \left(\frac{S_x}{z} \right), \quad \frac{\partial T}{\partial y} = \frac{1}{\delta} \tan^{-1} \left(\frac{S_y}{z} \right) \quad (3.3)$$

Izraz 3.3 pretvara dvije slike pomaka centra mase u slike gradijenta debljine objekta. Te slike gradijenta možemo integrirati kako bi dobili funkciju debljine $T(x, y)$ koristeći teorem za Fourierovu transformaciju derivacije funkcije,

$$\mathfrak{F} \left(\frac{\partial T}{\partial x} \right) = ik_x \mathfrak{F}(T) \quad (3.4)$$

gdje je $\mathfrak{F}$ Fourierova transformacija,

$$\mathfrak{F}(T(x, y)) = \frac{1}{2\pi} \iint_{-\infty-\infty}^{\infty\infty} T(x, z) e^{-i(k_x x + k_y y)} dx dy \quad (3.5)$$

gdje su (k_x, k_y) Fourierove koordinate. Tada funkciju debljine objekta možemo računati koristeći dva gradijenta debljine $\frac{\partial T}{\partial x}$ i $\frac{\partial T}{\partial y}$ prema izrazu 3.6 (Morgan et al. 2001.).

$$T = \Im^{-1} \left[\frac{\Im \left(\frac{\partial T}{\partial x} + i \frac{\partial T}{\partial y} \right)}{ik_x - k_y} \right] \quad (3.6)$$

Pomoću navedene funkcije debljine objekta dobivamo trodimenzionalnu rekonstrukciju objekta. Pogledamo li u poglavlje 2.1 vidjet ćemo da smo baš preko funkcije debljine modelirali naš objekt, tu istu funkciju dobivamo izračunima opisanom u ovom poglavlju. Rekonstrukcijom objekta zaokružili smo cjelinu našeg modela optičkog sustava, s koherentnim svjetlom obasjavamo predmet proziran zbog kojeg nastaju pomaci u fazi i preko tih pomaka rekonstruiramo naš objekt. Kako je ranije navedeno u ovom poglavlju rezolucija slike koju dobivamo ograničena je optičkom rešetkom drugim riječima broj rupica na rešetci određuje broj piksela u dobivenoj slici. Postavlja se pitanje možemo li dobiti sliku veće rezolucije. Odgovor pronalazimo u metodi sažimajućeg očitavanja koja može iz malog broja mjerenja rekonstruirati sliku visoke rezolucije.

4. Sažimajuće očitavanje

Poznati Shannonov teorem o očitavanju signala govori da je signal potrebno očitati najmanje dva puta većom frekvencijom od najveće frekvencijske komponente u spektru, Nyquistove frekvencije. Također jedan od osnovnih teorema linearne algebre govori da broj uzoraka (mjerena) diskretnog konačnog signala bi trebao biti barem jednak njegovoj duljini kako bi njegova rekonstrukcija bila moguća. Ove principe očitavanja signala pronalazimo u većini današnjih uređaja koji na neki način očitavaju signale. Sažimajuće očitavanje (engl. *Compressive Sensing* CS) pruža novi pristup očitavanju signala koji nadilazi ograničenja gore navedenih teorema. Sažimajuće očitavanje je metoda očitavanja signala znatno ispod Nyquistove frekvencije.

4.1. Motivacija

Kako bi opisali motivaciju iza ove metode poslužit ćemo se primjerom procesa fotografiranja i spremanja slike modernom digitalnom kamerom. Uobičajeni proces kojim fotografiramo slike s digitalnom kamerom je sljedeći: svjetlost pada na leće kamere te senzori kamere prikupljaju N uzoraka svjetlosnog vala, očitava se signal te dobivamo sliku. Kako je N vrlo veliki broj zbog uštede memorije dolazi potreba za kompresijom slike koje se najčešće temelji na transformacijskom kodiranju gdje se izračunava N transformacijskih koeficijenata te se K najvećih koeficijenata, koji su dovoljni za rekonstrukciju, pohranjuje dok se ostalih $N - K$ koeficijenata odbacuje. Kompresija ovakve vrste se zasniva na svojstvu rijetkosti signala te je rijetke signale moguće predstaviti s K najznačajnijih koeficijenata. Možemo primijetiti da ovakav proces neučinkovit jer imamo uređaj (u našem slučaju digitalna kamera) koji može prikupiti jako puno uzoraka koje nakon kompresije zadržimo u vrlo malom broju, računamo transformacijske koeficijente svih N uzoraka te kodiramo i pohranjujemo lokacije svakog od K najvećih koeficijenata. Metoda sažimajućeg očitavanja rješava ove probleme tako što se zaobilazi središnja faza kompresije te se odmah dohvaćaju značajni uzorci iz kojih je moguće rekonstruirati signal od N uzoraka.

4.2. Osnovna svojstva

Jednodimenzionalni diskretni konačni vremenski signal x možemo predstaviti s vektorom veličine N u vektorskom prostoru $\mathbb{R}^N$ s elementima $x[n], n = 1, 2, 3, 4 \dots N$. Baza u linearnoj algebri nekog vektorskog prostora V je uređeni skup međusobno linearno nezavisnih ne-nul vektora čijom se linearnom kombinacijom može jednoznačno predstaviti svaki drugi vektor iz V . Uzmemo li bazu $\Psi = [\psi_1, \psi_2, \dots, \psi_{1n}]$ gdje su ψ_i redci matrice tada signal x možemo prikazati izrazom

$$x = \sum_{i=1}^N s_i \psi_i = \Psi s \quad (4.1)$$


gdje s vektor transformacijskih koeficijenata. Možemo primijetiti da su s i x ekvivalentne reprezentacije signala gdje je x reprezentacija u vremenskoj ili prostornoj domeni dok je s u Ψ domeni.

Za signal x kažemo da je K -rijedak ako je linearna kombinacija K vektora baze odnosno da samo K koeficijenata s_i su različita od nule. Kažemo da je signal x rijedak ako je $K \ll N$ odnosno ako sadržava mali broj uzoraka različitih od nule te je takav signal kompresibilan. Velika većina signala koje susrećemo u praksi su rijetka.

Metoda sažimajućeg očitavanja omogućuje dohvat male količine podataka koje nazivamo mjere iz kojih se može rekonstruirati signal od N uzoraka. U procesu uzimanja uzoraka uzimamo M mjera (izraz 4.2) koje dobivamo produkt mjerne matrice čije su dimenzije $M \times N$ i početnog signala x zapisanog prema kao u izrazu 4.1.

$$y = \Phi x = \Phi \Psi s = \Theta s \quad (4.2)$$

Proces uzimanja uzoraka nije adaptivan što znači da je mjerna matrica Φ fiksna i ne ovisi o početnom signalu x . Problem metode sažimajućeg očitavanja možemo podijeliti na dva dijela: konstrukcija stabilne mjerne matrice Φ takve da sve istaknute informacije u bilo kojem K -rijetkom kompresibilnom signalu budu sačuvane bez obzira na redukciju dimenzionalnosti s $x \in \mathbb{R}^N$ na $y \in \mathbb{R}^N$ te na dizajn rekonstrukcijskog algoritma kako bi se mogao rekonstruirati signal x iz samo $M \approx N$ mjera.



Slika 4.1 Slikovni prikaz izraza 4.1. Slika preuzeta iz (Richard, 2007)

4.3. Dizajn mjerne matrice

Mjerna matrica Φ mora biti dizajnirana tako da omogućuje rekonstrukciju početnog signala x duljine N iz $M < N$ mjerenja. Možemo odmah uočiti da ovako postavljen problem se čini nemoguće razriješiti, ali ako uzmemo u obzir početnu pretpostavku da je signal x K -rijedak u nekoj bazi i ako su nam poznate lokacije K elemenata koji su različiti od nule onda je ovaj problem rješiv ako je ispunjen uvjet $M \geq K$. Nužan i dovoljan uvjet za ovakav pojednostavljeni problem definiramo na slijedeći način: za neki vektor v koji dijeli istih K zapisa različitih od nule kao s za neki $\epsilon > 0$ vrijedi:

$$1 - \epsilon \leq \frac{\|\Theta v\|_2}{\|v\|_2} \leq 1 + \epsilon \quad (4.3)$$

odnosno matrica Θ mora sačuvati duljine ti K -rijetkih vektora. U stvarnosti mi ne poznajemo lokacije tih K elemenata koji su različiti od nule međutim dovoljan uvjet za dizajn mjerne matrice koja omogućava stabilnu rekonstrukciju za K -rijetke i kompresibilne signale je da Θ zadovoljava uvjet 4.3 za proizvoljni $3K$ -rijedak vektor v . Ovaj svojstvo se naziva restriktivno izometrijsko svojstvo (engl. *Restricted Isometry Property* RIP). Povezano svojstvo nepovezanosti (engl. *incoherence*) zahtjeva da redci $\{\Phi_j\}$ matrice Φ ne mogu rijetko predstaviti stupce $\{\psi_j\}$ matrice ψ i obrnuto.

Kako bi direktno konstruirali mjernu matricu Φ takvu da $\Theta = \Phi\psi$ zadovoljava RIP svojstvo morali bi ispitati uvjet 4.3 za $\binom{N}{K}$ mogućih kombinacija K zapisa u vektoru v dinjine N . Dizajniranje ovakve matrice Φ je NP težak problem, ali nasreću dvojica ruskih matematičara Kashin i Gluskin su dokazali da s vrlo velikom vjerojatnošću Bernoullieva i matrica sa

slučajnim Gaussovim vrijednostima zadovoljavaju RIP svojstvo te svojstvo nepovezanosti. Uzmimo za primjer matricu Φ čiji su elementi Φ_{ij} nezavisni i jednako distribuirani (engl. *independent and identically distributed iid*) nasumične vrijednosti dobivene iz Gaussove razdiobe sa srednjom vrijednošću nula i varijancom $\frac{1}{N}$, tada mjere y su samo M različitih linearnih kombinacija elemenata od x koje su dodatno pomnožene s nasumičnom vrijednosti kako je prikazano na slici 4.1. Mjerna matrica s vrijednostima dobivenim iz Gaussove razdiobe ima dva vrlo zanimljiva svojstva. Prvo je da matrica Φ inkoherentna s bazom $\psi = I$ s vrlo visokom vjerojatnošću. Takva matrica dimenzija $M \times N$ sa iid svojstvom $\Theta = \Phi I = \Phi$ možemo pokazati s velikom vjerojatnošću da zadovoljava RIP svojstvo ako je ispunjen uvjet $M \geq cK \log\left(\frac{N}{K}\right)$ gdje je c mala konstanta. Tada K -rijedak signal koji je kompresibilan duljine N možemo rekonstruirati iz samo $M \geq cK \log\left(\frac{N}{K}\right) \ll N$ nasumičnim mjerenja. Drugo svojstvo matrice čije su vrijednosti dobivene iz Gaussove razdiobe je univerzalna u smislu da $\Theta = \Phi\psi$ će biti iid te će zbog toga s visokom vjerojatnošću zadovoljavati RIP svojstvo neovisno o izboru baze ψ . (Richard, 2007)

4.4. Rekonstrukcijski algoritmi

Sada dolazimo do problema rekonstrukcije signala x duljine N ili njegovog ekvivalentnog prikaza s iz M mjerenja koja su zapisana u vektoru y , mjerne matrice Φ te baze ψ . Kako je $M < N$ postoje beskonačno mnogo vektora s' koji zadovoljavaju jednadžbu:

$$\Theta s' = y \quad (4.4)$$

Ipak zahvaljujući svojstvu rijetkosti početnog signala postoji mogućnost određivanja rješenja koje najbolje aproksimira signal. U nastavku ovog poglavlja predstavljeni su algoritmi za rekonstrukciju signala.

4.4.1. L2 norma

Najčešći pristup rješavanja problema rekonstrukcije signala je minimizacija ℓ_p norme vektora s gdje ℓ_p normu vektora s definiramo kao

$$(\|s\|)_p^p = \sum_{i=0}^N |s_i|^p \quad (4.5)$$


Izraz za $p = 1$ postaje Manhattan norma, a za $p = 2$ euklidska norma. Pri definiranju problema rekli smo da algoritam mora pronaći rješenje koje je rijetko. Klasični pristup je upotreba ℓ_2 minimizacije(4.5).

$$\hat{s} = \min_{s' \in \mathbb{R}^N} \|s'\|_2, \quad \text{uz uvjet } \Theta s' = y \quad (4.6)$$

Pozitivna činjenica ℓ_2 norme je ta da izraz za minimum postoji u zatvorenoj formi:

$$\hat{s} = \Theta^T(\Theta\Theta^T)^{-1}y \quad (4.7)$$

Nažalost ℓ_2 minimizacija gotovo nikada neće dati K -rijetko rješenje, umjesto toga dobivamo rješenje koje ima puno elemenata različitih od nule. Razlog tome je što ℓ_2 daje vektor s najmanjom energijom. Na slici 4.2 vidimo da sa ℓ_2 normom mi „napuhujemo“ sferu sve dok ona ne presiječe ravninu na kojoj se nalaze rješenja, a kako nagib te ravnine ovisi o mjernoj matrici Φ koju smo generirali nasumično mi s ℓ_2 normom dobivamo kriva rješenja za naš problem. Kako znamo da je signal rijedak moramo tražiti rješenja koja se nalaze na koordinatnim osima.



Slika 4.2 a) Potprostor u kojemu se nalazi rijedak vektor blizu koordinatnih osi. b) Vizualizacija ℓ_2 norme. c) Vizualizacija ℓ_1 norme

4.4.2. L_0 norma

Kako ℓ_2 norma mjeri energiju signala, a ne njegovu rijetkost bolje rješenje je ℓ_0 norma koja označava broj elemenata različitih od nula u vektoru s' . Minimizacija ℓ_0 norme točno odgovara našim zahtjevima da vektor ima što manje elemenata manjih od nule. U ovom slučaju modificirana optimizacija dana je izrazom 4.8.

$$\hat{s} = \min_{s' \in \mathbb{R}^N} \|s'\|_0, \quad \text{uz uvjet } \Theta s' = y \quad (4.8)$$

Ovakva optimizacija može rekonstruirati K -rijedak signal s vrlo velikom vjerojatnošću koristeći samo $M = K + 1$ mjerenja. Međutim rješavanje ove optimizacije je nestabilno i predstavlja NP težak problem jer zahtjeva iscrpnu pretragu svih $\binom{N}{K}$ mogućih lokacija na kojima se nalaze elementi različiti od nule.

4.4.3. L1 norma

Optimizacija koja se temelji na ℓ_1 normi:

$$\hat{s} = \min_{s' \in \mathbb{R}^N} \|s'\|_1, \quad \text{uz uvjet } \Theta s' = y \quad (4.9)$$

može pouzdano i točno rekonstruirati K -rijedak ili aproksimativno kompresibilan signal s velikom vjerojatnošću koristeći samo *iid* Gaussovskih mjerenja. Ovo je problem konveksne optimizacije koji se može svesti na linearno programiranje čija je složenost $O(N^3)$. Na slici 4.2 vidimo da ℓ_1 sfera je poravnata s koordinatnim osima tako da za razliku od ℓ_2 optimizacije dobivamo rješenje koje se nalazi na koordinatnim osima upravo iz tog razloga dobivamo rješenje koje je rijetko.


5. Implementacija i rezultati

Kako bi testirali ispravnost razvijenog modela optičkog sustava izvodimo nekoliko virtualnih eksperimenata te dobivene rezultate uspoređujemo s rezultatima koji se dobivaju empirijski u stvarnom sustavu. Optički sustav je razvijen uz pomoć teoretskih modela koji su opisani prethodno u radu, a za implementaciju je korišteno programsko okruženje MATLAB.

MATLAB (engl. *Matrix Laboratory*) je programski jezik visoke razine namijenjen za tehničke proračune. Objedinjava računanje, vizualizaciju i programiranje u lako uporabljivoj okolini u kojoj su problem i rješenje definirani poznatom matematičkom notacijom. MATLAB se može koristiti za niz aplikacija, uključujući obradu signala, obradu sustava kontrole, ispitivanja i mjerenja, računalnih financija i računalne biologije (Matlab, 2017). Izabrali smo MATLAB jer je jezik visoke razine koji pruža mnoge ugrađene funkcije i programske knjižice za matematičke proračune te je stoga idealni jezik za brzo prototipiranje jer se korištenjem ugrađenih funkcija fokus usmjerava samo na implementaciju modela.

5.1. Eksperimenti s jednom pukotinom

S prvim eksperimentom kojeg izvodimo želimo dobiti rezultate prolaska svjetlosti kroz prazan prostor. Teorijske osnove potrebne za realizaciju ovog pokusa dane su poglavljima: 1.1, 1.2, 1.3. Eksperiment se izvod tako da monokromatsku svjetlost propustimo kroz jednu pukotinu te na određenoj udaljenosti postavimo senzor s kojeg čitamo rezultate (Slika 5.1). Veličina pukotine koju koristimo je $64 \times 64 \mu m$, valna duljina svjetlosti $\lambda = 632.8 nm$, udaljenost senzora od pukotine $z = 0.001 m$ te je udaljenost između uzoraka, frekvencija uzorkovanja, jednaka desetini valne duljine svjetlosti odnosno $sd = 6328 nm$.



Slika 5.1 Skica optičkog sustava s jednom pukotinom

Najvažnija dio kôda u ovom pokusu je implementacija Huygens-Fresnelovog principa (Kôd 5.1), za to iskorištena metoda opisana u poglavlju 1.3. Za implementaciju su korištene MATLAB funkcije ($Y = \text{fft}(X)$ i $Y = \text{ifft}(X)$) za računanje diskretne Fourierove transformacije korištenjem algoritma brze Fourierove transformacije (engl. *fast Fourier transform* FFT). Treba primijetiti da zbog toga što računamo konvoluciju signal moramo nadopuniti nulama zbog efekta rubova.


```
function U = fresnel_advance (U0, dx, dy, z, lambda)
% Funkcija prima kompleksno polje U0 s valnom
% duljinom lambda te vraća vrijenost polja na
% udaljenosti U koja se računa pomoću
% Hyugens-Fresnelovog principa, dx i dy su
% prostorne rezolucije.

k=2*pi/lambda;
% Računanje Furierovih koordinata
[ny, nx] = size(U0);
Lx = dx * nx;
Ly = dy * ny;
dfx = 1./Lx;
dfy = 1./Ly;
u = ones(nx,1)*(1:nx)-nx/2)*dfx;
v = ((1:ny)-ny/2)'*ones(1,ny)*dfy;
O = fftshift(fft2(U0));
% Izračun konvolucije izraza 1.2 u Furierovoj domeni
H = exp(1i*k*z).*exp(-1i*pi*z*lambda*(u.^2+v.^2));
U = ifft2(ifftshift(O.*H));

end
```


Kôd 5.2 – Implementacija Huygens-Fresnelovog principa

Na slici 5.2 vidimo rezultat ovog eksperimenta koji je u skladu s očekivanjima. Kada svjetlost pada na pukotinu svaka točka pukotine djeluje kao izvor novog sfernog vala te na senzoru dobivamo ogibnu sliku koja je rezultat interferencije svih valova. Vrijeme izvođenja ovog pokusa je 2.573006 sekunde, računski najzahtjevniji dio je računanje Fourierove transformacije.



Slika 5.2 Rezultat difrakcije svjetlosti na pukotini

Drugi eksperiment je samo nadogradnja prvoga te za njega koristimo isti kôd kojega proširujemo implementacijom modela tanke leće. Za izvedbu drugog pokusa postavljamo objekt između pukotine i senzora te koristimo iste mjere za veličinu pukotine, valnu duljinu svjetlosti, udaljenost senzora te udaljenost uzoraka. Objekt postavljamo neposredno ispred pukotine kako je prikazano na slici 5.3.



Slika 5.3 Skica optičkog sustava s jednom pukotinom i objektom

Teorijske osnove za korištene za implementaciju modela tanke leće opisane su u drugom poglavlju. Dio koda koji dodajemo za izvedbu ovog pokusa izravna je implementacija izraza 2.2. u kojemu je glavni dio funkcija debljine tanke leće (tankog stakla) čiju implementaciju vidimo u kôdu 5.2. Pomoću funkcije debljine možemo modelirati bilo koji objekt, izraz 2.7 je model leće, ali to nas ne ograničava da na sličan način modeliramo i druge objekte sve

dok poznajemo funkcije koje opisuju njihove debljine. U kôdu 5.2 smo modeli objekt koji je polovina sfere.

```
function T = create_lens(size, d_max, f, k, n, samp_distance)
% Funkcija koja izračunava faznu transformaciju
% koju uzrokuje leća. Funkcija kao parametre
% prima veličinu, maksimalnu debljinu, žarišnu
% duljinu i indeks loma leće te valni broj te
% udaljenost uzoraka.

% Izračunaj funkciju debljine leće
D = lens_thickness(size, d_max, f, samp_distance, n);

% Jednadžba tanke leće
T = exp(1i * k * d_max) * exp(D .* 1i * k * (n-1));
end

function D = lens_thickness(size, d_max, f, samp_distance, n)
% Ova funkcija izračunava debljinu leće (tankog
% stakla). Funkcija prima veličinu, debljinu,
% žarišnu duljinu, indeks loma leće (tankog
% stakla) te razmak između uzoraka


% Generiranje „mreže“ s kojom uzorkujemo
% funkciju debljine
xs = [1 : (size / 2)] * samp_distance;
xs_neg = fliplr(xs).*(-1);
xs = [xs_neg xs];
[XS,YS] = meshgrid(xs);

r = abs(f * (1 - n));
z0 = r - D_max;
D = sqrt(r ^ 2 - (XS .^ 2 + YS .^ 2)) - z0;
end
```


Kôd 5.2 – Implementacija tanke leće i implementacija funkcija debljine leće

Rezultat drugog pokusa vidimo na slici 5.4 te je on u skladu s očekivanjima. U pokusu smo modelirali konveksnu leću koja skuplja svjetlost prema jednoj točki, žarišnoj točki, kako smo za žarišnu udaljenost odabrali $f = 0.001$ leća nije potpuno skupila svjetlost u jednu točku što i možemo vidjeti u rezultatu. Na slici 5.5 vidimo rezultat eksperimenta kada postavimo prizmu koja ima nagib 30° , vidimo da zbog utjecaja prizme centralna pruga se

pomakne u negativnom smjeru x osi. Dodani kôd ne utječe znatno na izvođenje programa te brzina izvođenja približno ista brzini izvođenja programa za prvi pokus.



Slika 5.4 Eksperiment s jednom pukotinom gdje je za objekt postavljena konveksna leća



Slika 5.5 Eksperiment s jednom pukotinom gdje je za objekt postavljena prizma

5.2. Rekonstrukcija objekta


Sljedeće što želimo postići je rekonstrukcija objekta. Teorijske osnove za rekonstrukcijsku metodu smo opisali u poglavlju 3, a ovdje ćemo opisati kako smo implementirali tu metodu. Na slici 3.1 možemo vidjeti da između rupica (okna) na optičkoj rešetci postoje mali razmaci, ti razmaci postoje kako bi na senzoru mogli odvojiti područja na kojima računamo centre

mase. Računanje centra mase u pojedinoj rupici rešetke je potpuno nezavisno o svim ostalim rupicama te programski možemo računati centre mase iterativno za svaku rupicu, u svakoj iteraciji propuštamo svjetlost samo kroz jednu rupicu. U praksi ovakvo rješenje je nezgrapno te bi iziskivalo ponavljanje pokusa onoliko puta koliko ima optička rešetka ima rupica. Način na koji možemo izbjeći ovaj problem je ponavljanje pokusa u četiri faze. Podijelimo li optičku rešetku u blokove od četiri rupice gdje svakoj rupici pridijelimo jednu fazu slika 5.5.

1	2	1	2
3	4	3	4
1	2	1	2
3	4	3	4

Slika 5.6 Prikaz faza u kojima se izvršava proračun

Propuštamo svjetlo samo kroz rupice koje pripadaju jednoj fazi te radimo izračune centara mase, isto ponavljamo za preostale tri faze, te smo s četiri mjerenja pokrili cijelu optičku rešetku.



Slika 5.7 Skica eksperimenta kojim rekonstruiramo objekt

Eksperiment izvodimo tako da prvo računamo referentne centre mase (kôd 5.3), bez postavljenog predmeta, te nakon toga postavljamo predmet i računamo koliko se u x i y smjerovima pomiču centri mase u svakoj rupici na senzoru. Treba primijetiti da zbog utjecaja predmeta dio intenziteta kojeg koristimo za izračun centra mase može prijeći granice prozora u kojemu se računa centar. Iz tog razloga je potrebno matricu na kojoj se računa


centar mase proširiti s nulama kako bi u uzeli u obzir sav intenzitet u slučaju da nešto svjetlosti prijeđe granice početnog prozora.

```
function [ x,y ] = center_of_mass( M )
% Računanje centra mase u matrici M.
% Kao rezultat se vraća pozicija centra mase (x,y)

[size_x, size_y] = size(M);
% Suma svih elemenata matrice.
total_sum = sum(M(:));
% Inicijalizacija početnih vrijednosti suma.
sum_y = 0; sum_x = 0;
% Računanje težinskih suma po x i y osi.
for i=1:size_x
for j=1:size_y
sum_x = sum_x + i*M(i,j);
sum_y = sum_y + j*M(i,j);
end
end
x = round(sum_x / total_sum);
y = round(sum_y / total_sum);
end
```

Kôd 5.3 – Računanje težinskog centra mase

Na slici 5.7 vidimo rezultat jednog takvog eksperimenta koji potpuno odgovara očekivanjima, predmet koji smo postavili ima oblik dijela sfere. Brzina izvođenja ovog eksperimenta ovisi o broju rupica na optičkoj rešetci te je najproblematičniji dio koda propagacija svjetlosti kroz prazan prostor koja je opisana u poglavlju 5.1. Za naš eksperiment smo uzeli optičku rešetku veličine 1024×1024 rupica gdje je svaka rupica veličine $8 \times 8 \mu m$ ostale veličine iste su kao u eksperimentima iz poglavlja 5.1 (valna duljina svjetlosti $\lambda = 632.8 \text{ nm}$, udaljenost senzora od pukotine $z = 0.001 \text{ m}$ te je udaljenost između uzoraka $sd = 6328 \text{ nm}$). Prosječna brzina izvođenja ovog programa je 49.06s.




Slika 5.8 Prikaz pomaka centara mase koji nastaje zbog objekta

5.3. Sažimajuće očitavanje


Način na koji radimo rekonstrukciju objekta je vrlo pogodan za implementaciju metode sažimajućeg očitavanja koja će nam omogućiti poboljšanje rezolucije rekonstruiranog objekta. U 4. smo poglavlju opisali teorijske osnove za tu metodu, a ovom poglavlju ćemo opisati kako smo proširili sustav tako da omogući izvedbu sažimajućeg očitavanja. Na slici 5.9 vidimo skicu sustava, nakon optičke rešetke postavljamo još jednu „finiju“ rešetku koja će nam služiti kao mjerna funkcija u sažimajućem očitavanju. Ta rešetka će na nasumično odabranim pozicijama propuštati svjetlo, a na ostalim pozicijama neće (omjer bi trebao biti oko 50%). Ako pozicije biramo iz Gaussove razdiobe na ovaj način konstruiramo mjernu matricu kao što je opisano u poglavlju 4.3. Za svaku rupu na optičkoj rešetci radimo niz mjerenja s različitim mjernim rešetkama, gdje jedno mjerenje definiramo kao izračun centra mase na senzoru isto kako smo ga računali u prethodnom poglavlju. Zbog utjecaja mjerne maske ti centri mase će se razlikovati te dobivamo vektor y (izraz 4.1) koji ima dimenzije $\text{broj mjerenja} \times 1$ iz kojeg kasnije rekonstruiramo početni signal x L1 normom. Eksperiment možemo izvoditi iterativno za svaku rupu optičke rešetke ili po fazama kako je opisano u prethodnom poglavlju. U eksperimentu smo koristili veličinu optičke rešetke 4×4 gdje je svaka rupa veličine $64 \times 64 \mu m$, mjerna maska je za svaku rupu optičke rešetke je se sastoji od 8×8 elemenata koji je svaki veličine $8 \times 8 \mu m$ što znači da je ukupna veličina mjerne maske 1024×1024 . ostale veličine iste su kao u eksperimentima iz poglavlja 5.1 (valna duljina svjetlosti $\lambda = 632.8 \text{ nm}$, udaljenost senzora od pukotine $z = 0.001 \text{ m}$ te je

udaljenost između uzoraka $sd = 6328 \text{ nm}$). Ako usporedimo ove brojeve možemo vidjeti da očekivana rezolucija objekta je ista kao u poglavlju 5.2 te tako možemo testirati uspješnost implementacije metode sažimajućeg očitavanja.




Slika 5.9 Skica sustava u kojemu s metodom sažimajućeg očitavanja rekonstruiramo objekt

Na slici 5.10 vidimo rezultat rekonstrukcije objekta korištenjem metode sažimajućeg očitavanja i usporedimo li dobiveni rezultat sa slikom 5.8 vidimo da ova metoda daje dobre rezultate. Za ovu rekonstrukciju smo mjernu matricu konstruirali tako da smo iz jedinične matrice nasumično odabrali 32 retka, a za transformaciju (vektorska baza Ψ iz izraza 4.1) smo koristili DCT (engl. discrete cosine transform).



Slika 5.10 Rezultat rekonstrukcije iz 32 mjerenja s jediničnom mjernom matricom, prikazani su pomaci centara mase

Na slici 5.11 vidimo rezultat rekonstrukcije s 32 mjerenja gdje je mjerna matrica generirana iz Gaussove razdiobe s točno 50% otvora te korištenjem DCT transformacije. Iz rezultata vidimo da ova metoda daje izvrsne rezultate te da smo uspjeli rekonstruirati objekt s 64 puta većom rezolucijom iz samo 32 mjerenja. Vrijeme izvođenja programa za ovaj eksperiment je 2128.71s. Glavni problem je što za svaki prozor računamo 32 puta intenzitet svijetla što se u prethodnim poglavljima pokazalo kao najsporiji dio sustava.




Slika 5.11 Rekonstrukcija iz 32 mjerenja s mjernom matricom dobivenom iz Gaussove razdiobe, prikazani su pomaci centara mase

6. Diskusija

U prethodnom poglavlju možemo vidjeti da rezultati koje dobivamo korištenjem optičkog sustava koji je razvijen u sklopu ovog rada odgovaraju rezultatima koji se dobivaju u stvarnim sustavima. Također smo pokazali da možemo uspješno rekonstruirati objekt te da metoda kojom rekonstruiramo objekt omogućava nadogradnju sustava tako da iz malog broja mjerenja možemo rekonstruirati objekt u većoj rezoluciji.

No, treba obratiti pažnju ne nekoliko detalja i limitacija ovog modela. Kao prvu stvar možemo primijetiti da vrijeme izvođenja programa koji koristi metodu sažimajućeg očitavanja je jako dugo na vrlo malom problemu koji se sastoji od samo 16 rupa na optičkoj rešetci, u stvarnosti broj rupa bi trebao biti za dva do tri reda veličine veći. Model je razvijen tako da se može vrlo lako paralelizirati, izračun na svakoj rupi ili svakoj fazi može se raditi paralelno te bi paralelizacija izračuna značajno olakšala korištenje modela. Druga stvar koju moramo primijetiti je greška koju uvodimo u sustav prilikom izračuna centra mase. Na slici 6.1 vidimo da zbog difrakcijskih pruga te zbog relativno velikog prostora na kojemu računamo centar mase dobivamo rezultat je netočan. Model bi mogli poboljšati naprednijom metodom izračuna centra mase. Kao treću stvar moramo obratiti pažnju na odabir baze Ψ u metodi sažimajućeg očitavanja, ovisno o obliku predmeta pomaci koje računamo mogu biti rijetki u različitim bazama.



Slika 6.1 Izračun centra mase, x označava izračunato mjesto centra mase

Zaključak

U ovom radu je opisana teorijska osnova te zatim i implementacija modela koherentnog optičkog sustava. Pomoću aproksimativnih modela koji se temelji na Huygens-Fresnelovog principa superpozicije točkastih izvora razvili smo matematički i simulacijski model koherentnog optičkog sustava te smo korištenjem optičke rešetke rekonstruirali objekt. Pokazali smo da rezultati koje dobivamo odgovaraju rezultatima iz stvarnih sustava te smo pokazali da se sustav može jednostavno proširiti kako bi pomoću metode sažimajućeg očitavanja iz malog broja mjerenja mogli rekonstruirati objekt u visokoj rezoluciji.

Literatura

- [1] GOODMAN. Introduction to Fourier Optics. Stanford University, 1996.
- [2] MORGAN, PAGANIN, SIU. Quantitative single-exposure x-ray phase contrast imaging using a single attenuation grid. School of Physics, Monash University, Clayton, VIC, 3800, Austral, 2001
- [3] RICHARD G. BARANIUK. Compressive Sensing. IEEE signal processing magazine [118] July 2007
- [4] MATLAB. URL: <https://www.mathworks.com/products/matlab.html> (lipanj.2017)

Sažetak

Naslov: Model koherentnog optičkog sustava korištenog u laserskoj mikroskopiji

U ovom radu je opisana teorijska osnova te je razvijen matematički i simulacijski model optičkog sustava. Optički sustav koristi laserski izvor koherentnog svjetla zadane valne duljine, a promatrani objekt je proziran te ima različitu brzinu prostiranja svjetlosti od vakuuma. Model je razvijen na temelju Huygens-Fresnelovog principa superpozicije točkastih izvora. Za modeliranje objekta je korišten matematički model tanke leće te je on modeliran kroz faznu karakteristiku sustava. Rupičastim odnosno rešetkastim strukturama simulirane su mjerne funkcije te je rekonstruirana slika objekta visoke rezolucije iz malog broja mjerenja sažimajućim očitavanjem. Model je realiziran u programskom okruženju MATLAB.

Ključne riječi: Huygens-Fresnelov princip; Fresnelova aproksimacija; tanka leća; sažimajuće očitavanje

Summary

Title: Coherent Optical System Model Used in Laser Microscopy

This paper describes the theoretical basis and implementation of coherent optical system model used in laser microscopy. The optical system uses coherent source of light with fixed wavelength. The object is transparent and within object speed of light is less than in a vacuum. A model is developed with the use of Huygens -Fresnel principle. We used mathematical model of thin lens for object implementation. We reconstruct object with phase contrast imaging using a single attenuation grid. With usage of another grid we take measurements for compressive sensing and using those measurements we reconstruct image of high resolution. The model is implemented in a software environment MATLAB.

Key words: Huygens-Fresnel Principle; Fresnel approximation; thin lenses; compressive sensing

Skraćenice

FFT Fast Fourier transform

CS Compressive Sensing

RIP Restricted Isometry Property

DCT discrete cosine transform

iid independent and identically distributed

Privitak

Eksperimenti opisani u radu izvršavaju se pokretanjem MATLAB skripti: za prvi eksperiment (poglavlje 5.1) `opticki_sustav.m`, drugi eksperiment (poglavlje 5.1) `opticki_sustav_s_objektom.m`, treći eksperiment (poglavlje 5.2) `opticki_sustav_rekonstrukcija_objekta.m` te za četvrti (poglavlje 5.3) eksperiment `opticki_sustav_sazimajuce_ocitavanje.m`. U skriptama se koristi programska knjižica SeDuMi koju je potrebno dodati u putanju.